

TopoContour-Mamba:

基于增广等高线树的拓扑引导视觉序列化

Dian Yu

独立研究者

<https://github.com/sdsds222/>

摘要

视觉状态空间模型必须先把图像排成序列，再执行选择性扫描，因此路线决定哪些信息先进入历史、哪些信息靠近最终读出。多数视觉路线对所有图像固定。本文提出 TopoContour-Mamba：用确定性显著性场为每张图像生成路线，再沿路线直接读取原图像素。完整等高线树提供延续、分裂、汇合、源点和终止关系；只有值得扫描的常规轮廓才插入稀疏执行树。每个保留轮廓先按周长确定点数，再由均匀试探点读取同一张 Sobel 场：法线方向响应的平均符号为整圈选择低显著性普通读取侧，平滑后的响应强度重分配固定点数，最大强度位置确定共同起止点 p_0 。Normal Mamba 从首次碰撞点读回带 Tag 的轮廓点。两次共享参数的 Contour Mamba 扫描从 p_0 出发，按相反方向遍历同一组闭环点，并在带 Tag 的 p_0 副本结束。每条树枝的终止圈读取两侧法线，再用第二对闭环汇集。所有轮廓独立编码完成后，Tree Mamba 才从低显著性向高显著性汇总带 Tag 输出：分裂复制摘要，汇合采用与输入顺序无关、考虑采样支撑量的融合。最后，各终止叶按实际读取区域的显著性排序，并由最终 Mamba 完成分类。初版路线完全确定，不使用 CNN 特征 Stem。本文完整规定路线、Token 接口、边界情况、默认值和结构性质，不作实证性能声明。

1 引言

Mamba 通过输入相关的状态更新实现线性序列建模，但扫描前仍然需要确定 Token 顺序 [5]。Vision Mamba 通常采用栅格、方向、窗口或其他预先设计的路线 [17, 13, 16, 10]。这些路线便于并行计算，却不一定符合当前图像自身的结构。

本文的直觉很简单。人观察图像时，不会对所有区域投入相同精度：宽泛背景可以先获得粗略认识，醒目的局

部细节则得到更晚、更密集的读取。本文不声称模拟生物视觉，只把这一想法用于安排选择性状态空间模型的信息顺序。低显著性信息较早进入全局历史，高显著性信息较晚进入；热力变化快的位置获得更密的采样。每次 Mamba 扫描开始前，完整顺序都已经确定。

TopoContour-Mamba 从显著性标量场生成这个顺序。闭合等值线分量形成局部路线，等高线树记录这些分量随显著性升高而出现、延续、分裂、汇合和终止的关系 [4]。因此不需要把每个圈强制匹配到最近的下一层圈，也不会在盆地周围产生错误的远距离连接。细小树枝可以保留在拓扑中，但不一定消耗扫描 Token。

初版使用传统算法生成显著性场，并直接从原始 RGB 图像读取视觉内容，不包含 CNN 特征 Stem。同一张 Sobel 场统一完成三个决定：带符号的法线响应为整圈选择低显著性读取侧，响应强度决定圈内采样密度，最强的平滑响应位置确定公共锚点 p_0 。这样不再为方向、密度和起止点分别设计互不相关的规则。

局部读取与全局汇总严格分开。每个保留轮廓独立编码：Normal Mamba 从碰撞点读回带 Tag 的轮廓点；两条 Contour Mamba 从同一个 p_0 出发，按相反方向绕圈，并在带 Tag 的 p_0 副本结束。每条树枝的终止圈读取两侧法线，再进行第二次闭环汇集。所有局部编码完成后，Tree Mamba 才沿稀疏增广等高线树从低到高处理轮廓摘要。图 1 展示按照这些规则生成的一条完整路线。

本文贡献可概括为：

- 用闭合等值线与低到高的增广等高线树构造随输入变化的视觉序列；
- 用一套 Sobel 规则统一决定整圈读取侧、固定预算内的采样密度和公共锚点；
- 用带 Tag 的原图像素法线与闭环编码器完成局部读取，再以 Tree Mamba 处理分裂、无序汇合、终止叶和空路线。

本文给出完整的架构与算法规范。其贡献是确定性

路线构建、Token 接口、拓扑汇总规则和结构分析；本文不作实证性能声明。

2 相关工作

2.1 视觉状态空间模型的序列化

选择性状态空间模型接收有序序列，因此视觉模型必须同时决定空间邻接与读出方向。Vim 把图像 Patch 展平，并结合位置编码使用双向状态空间块 [17]。VMamba 的 SS2D 沿四条路线遍历特征网格，在保持稠密网格覆盖的同时组合多方向上下文 [13]。PlainMamba 用连续二维路线改善相邻 Token 的空间连续性，并加入方向感知更新 [16]。LocalMamba 把网格分成局部窗口，并为不同网络层搜索合适的扫描选择，以加强短程二维依赖 [10]。这些方法逐步改善了空间邻接，但基本几何单元仍是行列、连续网格路径或窗口，并不来自当前图像等值线的连通结构。

后续工作开始让路线随内容变化。DAMamba 通过 Dynamic Adaptive Scan 学习扫描顺序和区域 [12]。QuadMamba 预测 Token 局部性并递归划分窗口象限，以 Gumbel-Softmax 掩码和直通估计器训练离散分区 [15]。面向视频超分辨率的 MambaVSR 构建语义连通图、聚类相关内容，再沿所得空间顺序交织时域特征 [7]。它们与 TopoContour-Mamba 一样反对所有图像共享单一栅格顺序，但所组织的对象不同：前述方法调整排列、区域、象限或语义组；本文提取闭合等值线分量，并在等高线树中显式保留其分裂与汇合演化。初版路线是确定性的，因此这里只主张架构差异，不声称适应性更强。

PRISMamba 是最接近的几何对照。它把图像划分为同心环，在每个环内做与次序无关的聚合，再用短径向 SSM 在环之间传递上下文 [9]。TopoContour-Mamba 不假设统一中心或同心圆结构：同一层可以有多个不相连、非凸的轮廓，每圈沿弧长双向扫描；法线负责读取邻带，独立的等高线树负责全局低到高汇总。因此，PRISMamba 按图像中心组织稠密环，而本文按标量拓扑组织稀疏、随输入变化的等高线。

表 1：代表性视觉序列化规则。比较对象是路线结构，而不是 Mamba 门控本身。

方法	路线	与本文的关键区别
Vim / VMamba	Patch/网格方向	稠密坐标路线，不提取等值线拓扑
Plain-/LocalMamba	连续路径或窗口	在预设网格单元内改善连续性或局部性
DAMamba / QuadMamba	学习顺序、区域或象限	可训练空间组织，但无显式等高线树
MambaVSR	语义分组与图顺序	面向复原的内容路线，而非标量等值集
PRISMamba	同心环、统一中心，不描述分裂与汇合演化	
径向 SSM	法线、闭合轮廓与树	分离邻带读取、圈内编码和拓扑汇总
本文		

2.2 显著性、轮廓与拓扑结构

经典视觉注意模型组合亮度、颜色与方向线索，频率调谐显著性则在 Lab 空间测量对比度 [11, 1]。这类热力图表示自底向上的醒目程度，不保证等同于任务语义重要性。本文初版使用频率调谐方法，只为序列化实验提供可复现的标量场；任务相关 CNN 将在第 8 节讨论。由于硬轮廓提取是离散过程，必须明确其梯度边界。

等高线树记录标量阈值变化时，等值线连通分量如何出现、延续、分裂、汇合和消失 [4]。增广操作把常规轮廓或网格元素关联到树弧，按需增广可避免生成不需要的几何对象 [14, 6]。已有神经网络工作把等高线树层次或拓扑图用于分割 [8, 2]。本文既不预测等高线树，也不只把它作为损失；它是确定性执行图：常规轮廓定义相互独立的局部 Mamba 序列，只有完成后的带 Tag 输出在树上传递。

Graph Mamba 处理任意图邻域的排序和状态空间编码 [3]。本文使用的图更窄，也更受约束：标量值天然给每条树边低到高的方向，分裂与汇合语义已知，未采样路径可收缩而无需虚构最近邻连接。因此可以为不同事件使用专门算子——分裂复制、汇合无序融合、非分叉树段运行 Mamba——而不是套用统一的通用图 Token 规则。

本文定位。 创新点并非孤立地“换一条曲线”，而是把现有扫描设计常混在一起的三种关系分开：首次碰撞法线决定局部跨层证据，闭合等高线决定分量内部顺序，增广等高线树决定全局信息走向。表 1 陈述这些架构差异；本文贡献属于方法层面，不是实证优势声明。

3 路线构建

3.1 显著性场与稀疏增广树

设归一化原始 RGB 图像为 $I \in [0, 1]^{H \times W \times 3}$ 。确定性算法生成显著性场 $S \in [0, 1]^{H_r \times W_r}$ 。默认使用频率调谐 Lab 对比度 [1]，随后进行高斯平滑。模型从 I 读取 RGB； S 只负责构建路线并提供路线属性。

在路线网格外增加一圈低于场值范围的边框，使接触图像边缘的轮廓闭合。每个网格单元固定按西北到东南的对角线剖分，相同标量值使用确定性的符号微扰。保留扫描层级之前，先在完整分片线性场上建立等高线树 T 。补边后的矩形单连通，因此 T 无环。树可以同时包含分裂和汇合鞍点，但同一次分裂产生的兄弟支路不会再次汇合；汇合只组合具有独立低值来源的分支。有孔洞的定义域需要改用 Reeb 图。

在 L 个常规层级提取闭合轮廓，删除低于周长和面积阈值的小圈，并把其余轮廓插入对应树弧。没有保留轮廓的路径被收缩，得到稀疏执行树 T_A 。这样，树负责跨层拓扑，细小分支不必消耗 Token；法线碰到哪个对象都不会改变树边。

热力图平滑后，在路线网格上只计算一次 3×3 Sobel 场 $G = (G_x, G_y)$ 。所有轮廓共享这张场。

3.2 统一的 Sobel 方向、密度与锚点

对周长为 P_C 的保留轮廓 C ，先确定唯一点数：

$$N_C = \max(N_{\min}, \text{round}(P_C/\delta_0)). \quad (1)$$

默认 $N_{\min} = 16, \delta_0 = 2$ 。点数没有语义上的最大值；长圈进入更大的长度桶，或者使用不丢点的精确分块扫描。变密度操作只能移动固定数量的点，不能让某个局部额外产生 Token。

先把轮廓统一定向为顺时针，再沿弧长均匀放置 $M_C = 2N_C$ 个试探点。设试探点为 u_i ，按照统一环绕方向确定的单位法线为 n_i 。在 Sobel 场中双线性读取后，得到一个带符号的法线响应：

$$r_i = G(u_i)^\top n_i. \quad (2)$$

它的符号表示哪一侧热力值升高。若所有 r_i 的平均值不小于零，说明正法线整体指向高值侧，整圈普通法线统一选择负法线侧；否则统一选择正法线侧。平均值恰为零时固定选择负法线侧。每个圈只作一次方向判断，不允许采样点各自改变左右方向。

绝对强度 $g_i = |r_i|$ 表示热力图跨越轮廓时变化得多快。沿闭环用 $(1, 2, 3, 2, 1)/9$ 平滑一次，得到 $\bar{g}_i$ 。令 m_C

为正值 $\bar{g}_i$ 的中位数；如果整圈没有正响应，则全部密度权重设为 1。否则：

$$w_i = \text{clip}\left(\frac{\bar{g}_i}{m_C + \epsilon}, 1, 3\right). \quad (3)$$

弱变化区域保持基础密度，强变化区域获得更多点，最大权重限制避免小区域耗尽点数预算。当标量层级间隔固定时，较大的法线方向梯度也近似表示相邻等高线距离更短。

在尚未截断的平滑强度 $\bar{g}_i$ 中选择最大值所在试探点作为锚点 p_0 ；并列时选择图像坐标 (y, x) 字典序最小的点。因此，同一批 Sobel 测量同时确定读取侧、采样密度和起止点，试探阶段不需要碰撞查询。

对每个试探区间，把实际弧长乘以两端平均权重，得到加权弧长。以 p_0 为起点，在累计加权弧长上等间隔放置恰好 N_C 个最终点，并强制保留 p_0 。高权重区间的点更近，但总点数不变。整个过程不拉伸、不截断，也不补造几何点。顺、逆时针扫描使用同一组物理点的相反顺序。

只有重采样结束后才进行射线碰撞查询。每个最终点向整圈选定的普通侧发射射线，直到首次正向碰到其他保留轮廓折线或补边框；忽略起点接触和本轮廓的两条相邻线段。终止圈还会向相反侧发射第二条射线。路线坐标映射回原图后，RGB 与显著性都用双线性插值读取。试探点本身不成为模型 Token。

4 架构

4.1 直接读取原图的法线与轮廓编码

所有保留轮廓独立编码。任何父圈输出都不进入法线或闭环扫描。这是局部视觉读取与全局树汇总之间的明确分界。

考虑层级为 λ_C 的最终轮廓点 p 。路线构建已经为整圈固定普通读取侧 σ_C 。从 p 向该侧发射射线，首次碰撞为 q_p 。几何查询从 p 找到 q_p ，但 Normal Mamba 按相反方向读取，也就是从 q_p 回到 p 。

对法线采样位置 r ，记双线性读取的归一化 RGB 为 $c(r)$ 。输入还包含归一化图像坐标、 $(\lambda_C, S(r) - \lambda_C)$ 、从碰撞点到轮廓点的相对进度，以及法线实际长度。共享逐点投影 E_N 把这些值映射到模型宽度；它不是 CNN，也不会混合相邻图像位置。最后的轮廓点 p 加入法线终点 Tag：

$$n_p = \mathcal{M}_N(E_N[c, S - \lambda_C, \lambda_C, \hat{x}, \hat{y}, t, d]_{q_p \rightarrow p} + e_{N, \text{end}@p})_p. \quad (4)$$




图 1: 按照本文规则生成的一条实际路线。白线表示保留的非终止轮廓；红线及浅红区域表示每条可见树枝最后保留的终止圈。橙色箭头表示 Normal Mamba 从首次碰撞点 q 读回轮廓点 p 的普通侧法线；红色箭头表示仅在终止圈补读的相反侧法线。星号表示共同起点和带 Tag 返回点 p_0 ，蓝色与紫色箭头表示两个闭环方向。

设计哲学。这条路线并不把低显著性区域判定为无用信息，也不删除它们。宽泛背景先进入历史；Sobel 变化较弱的地方采样相对稀疏，而轮廓变化明显、位于树枝终点的证据后进入并更靠近带 Tag 的读出。因此，选择性遗忘在这里被用作一种注意力调度：较弱背景可以逐渐变模糊但仍然存在，辨识度较高的证据则较少受到后续更新影响。这只是归纳偏置，并不保证 Mamba 无损记忆。由于几何路线在扫描前已经确定，而且各轮廓的局部编码互相独立，图像相关的顺序仍可保持法线之间和轮廓之间的并行执行。

带 Tag 输出 n_p 是该条原图 RGB 法线序列的摘要。

构造轮廓点 Token 时，仍直接加入端点 RGB，而不要求 n_p 无损保存它。共享投影 E_C 把 n_p 、 $c(p)$ 、归一化坐标、 λ_C 、当前点代表的局部弧长，以及法线方向和长度组合成 x_p 。坐标告诉 Mamba 点在二维图像中的位置；局部弧长则说明变密度采样后相邻 Token 的真实间距。

设最终点为 $(p_0, \dots, p_{N_C-1})$ ，其中 p_0 是重采样时保留的 Sobel 锚点。闭合曲线没有天然起点，因此只在序列层面从 p_0 切开，几何上仍保持闭环。两个方向都从不带轮廓终点 Tag 的 p_0 开始。顺时针依次访问 p_1 到 p_{N_C-1} ；逆时针按相反顺序访问同一组点。最后都回到第二个 p_0 ，只有返回副本带轮廓终点 Tag：

$$X_C^\circ = (x_{p_0}, x_{p_1}, \dots, x_{p_{N_C-1}}, x_{p_0} + e_{C,\text{end}}), \quad (5)$$

$$X_C^\circ = (x_{p_0}, x_{p_{N_C-1}}, \dots, x_{p_1}, x_{p_0} + e_{C,\text{end}}). \quad (6)$$

每个非锚点在每个方向中出现一次；锚点分别作为不带 Tag 的开头和带 Tag 的结尾。两个带 Tag 返回位置的输

出经拼接、投影和归一化得到局部轮廓 Token y_C 。Tag 只固定读出位置，不保证无损记住全圈。终止圈还会保留两方向对齐后的逐点输出。

终止圈的双侧读取。若 C 没有更高的有效后继，它就是该树枝最后一个保留圈。此时，普通侧法线和第一对闭环已经完成。每个点再向 σ_C 的相反侧寻找首次碰撞，第二侧 Normal Mamba 同样从碰撞点读回带 Tag 的轮廓点 p 。

在每个 p 上，把第二侧法线输出与第一次顺、逆时针闭环在该点的对齐输出融合。第一次闭环输出中已经包含普通侧法线信息。融合后的点再由同一 Contour Mamba 执行第二对闭环，继续使用同一个 p_0 、同一组采样点、相反的环绕顺序和带 Tag 的返回终点。两个最终输出融合为 y_C^{term} 。因此终止结果同时包含两侧法线，而不是用另一侧替换普通侧。峰点、宽峰环和盆地边界都使用同一规则，不需要判断是否填充内部。




图 2: 树级汇总。分裂复制一个带 Tag 摘要; 汇合以无序方式组合独立产生的分支。同一次分裂产生的兄弟支路不会在树中再次汇合。

法线、普通闭环和终止闭环都按真实长度分桶。填充位置放在真实带 Tag 终点之后并被屏蔽, 读出始终索引真实终点。

4.2 Tree Mamba 汇总

所有局部 Token 产生后, 才从低到高处理 T_A 。最大非分叉树段 B 包含按标量值排列的轮廓 $(C_1, \dots, C_r)$ 。共享 Tree Mamba 接入口摘要和局部轮廓 Token:

$$b_B = \mathcal{M}_G(y_B^{\text{in}}, y_{C_1}, \dots, y_{C_r} + e_{\text{seg}})_r. \quad (7)$$

终止圈在树段中使用 y_C^{term} 替换第一次的 y_C 。树源使用可学习入口 Token。最后一个真实轮廓带树段终点 Tag; 若它也是拓扑叶子, 再加叶子 Tag。跨树段只传递带 Tag 输出 y , 不传隐藏状态、卷积缓存或其他循环状态。

分裂鞍点把 b_B 复制给各条输出树段。同一次分裂产生的兄弟支路不会在等高线树中再次汇合, 因此不需要循环协调规则。

汇合鞍点的输入来自不同低值源, 没有天然顺序。设第 i 条分支摘要为 b_i , 其历史代表的唯一最终轮廓采样点数为 Q_i 。采用考虑支撑量且与输入排列无关的融合:

$$s_i = \frac{1}{2} \log(1 + Q_i) + \mathcal{G}(\text{LN}(b_i)), \quad (8)$$

$$\alpha_i = \frac{\exp(s_i)}{\sum_j \exp(s_j)}, \quad b_{\text{join}} = \text{LN}\left(W_J \sum_i \alpha_i b_i + e_{\text{join}}\right). \quad (9)$$

$\mathcal{G}$ 的末层采用零初始化, 因此开始时近似按采样支撑量的平方根加权, 之后再学习内容修正; 整个过程不依赖不稳定的 $\|y\|$ 。同一算子适用于任意汇合度。

4.3 带 Tag 的最终读出

每条终止叶产生摘要 ℓ_k 。对终止轮廓的每个点, 先在终止编码器实际使用的两侧法线上计算显著性均值, 再按每个点代表的真实弧长组合这些分数, 得到排序分数 ρ_k 。这样不会因为某处采样更密就让它重复投票。

叶子按 ρ_k 从低到高排列。相同值依次用终止极值和质心坐标破平局。所有 Token 加入 e_{leaf} , 最后一个再加入 e_{final} :

$$g = \mathcal{M}_G(\ell_{\pi(1)} + e_{\text{leaf}}, \dots, \ell_{\pi(K)} + e_{\text{leaf}} + e_{\text{final}})_K. \quad (10)$$

只有一个叶子时也使用两个 Tag。若没有轮廓通过过滤, 则把原图 RGB 各通道的均值和方差进行投影:

$$g = \text{LN}(W_0[\text{Mean}(I), \text{Var}(I)] + e_{\text{empty}}). \quad (11)$$

最后使用线性分类头输出类别。

内部汇合与最终叶子排序承担不同功能。内部汇合是没有顺序的拓扑事件, 必须使用无序融合; 最终叶子只在全局读出时按实际读取显著性序列化一次, 使较弱终止证据先进入、较强证据后进入。

5 前向过程与并行执行

初版路线规划完全确定, 并在任何 Mamba 扫描之前结束。完整前向过程如下:

不同长度的法线、闭环和树段采用动态长度桶分批。填充位置位于真实带 Tag 终点之后并被屏蔽。所有法线与局部轮廓编码器相互独立, 可以跨层并行; 树上同一就绪前沿的树段也可并行。必须保持顺序的部分只有单条法线或闭环内部、低到高的树边以及最终叶子序列。长圈使用更大的桶或不丢点的精确分块, 不允许截断或几何拉伸。

跨树段只传递带 Tag 的 y 。分裂复制一个向量, 而不是复制参数、隐藏状态或循环缓存。初版中, 原图属性的逐点投影和所有 Mamba 模块可以训练; 传统显著性算法、Sobel 决策、轮廓提取和硬树结构都是停止梯度的路线构建。未来若加入显著性 CNN, 需要单独的软训练路径。

6 结构分析

随输入变化的伪时序。 固定栅格或十字路线按坐标排列像素; TopoContour-Mamba 让显著性场决定闭合局部路线和低到高的树顺序。较弱区域较早进入全局历史, 显

算法 1: TopoContour-Mamba 前向过程

1. 归一化原图 RGB，计算确定性显著性场，完成平滑并生成一张 Sobel 场。
2. 在补边后的分片线性显著性场上建立完整等高线树；提取保留轮廓、过滤小圈、插入树弧，并收缩没有采样轮廓的路径。
3. 每个圈统一定向并按周长确定点数。均匀试探点读取带符号的法线 Sobel 响应：平均符号决定整圈低值普通侧，平滑强度决定密度，最大强度位置决定 p_0 。
4. 从 p_0 开始按加权弧长重分配固定点数。只在最终点上查询普通侧的首次碰撞。
5. 沿所有普通法线读取原图 RGB 与路线属性，从碰撞点扫描到带 Tag 的轮廓点；构造轮廓点 Token，再从 p_0 开始按两种方向扫描到带 Tag 返回点，得到 y_C 。
6. 每个终止圈还扫描相反侧法线，与第一次闭环的逐点输出融合，再重复两条从 p_0 到带 Tag 返回点的闭环，得到 y_C^{term} 。
7. 从低到高处理稀疏树：Tree Mamba 扫描非分叉树段；分裂复制带 Tag 的 y ，汇合进行支撑量感知的无序融合。
8. 根据终止圈实际读取的两侧法线计算叶子显著性，并按弧长支撑量加权；叶子从低到高排序后交给最终 Merge Mamba。
9. 若没有有效圈，则投影原图 RGB 各通道的均值和方差；输出分类结果。

著区域更接近最终带 Tag 读出。选择性状态更新可能保留宽泛的早期背景并强调较晚证据，但这只是归纳偏置，不是对 Mamba 记忆行为的保证。

三种关系严格分工。 法线读取轮廓邻带，双向闭环整合一个连通分量，增广等高线树跨标量层级汇总。射线碰撞不决定父子关系，父圈摘要也不进入局部轮廓编码。树可以包含分裂和汇合，但因为它无环，同一次分裂产生的兄弟支路不会再次汇合；汇合组合的是具有独立低值来源的分支。

一个 Sobel 信号完成三个决定。 每个均匀试探点的带符号法线 Sobel 响应表示哪一侧热力值升高；平均符号为整圈确定普通读取侧，平滑绝对强度决定密度，最强位置固定 p_0 。三个决定来自同一局部测量的不同部分，规则简单，也省去了试探阶段的碰撞查询。与此同时，强变化区域既获得更多点，又靠近带 Tag 的闭环终点，这是一种有意的双重强调，必须与均匀采样和独立锚点进行消融比较。

固定预算的原图采样。 周长决定每个圈有多少点，Sobel 权重只移动这些点。累计加权弧长把固定预算集中到跨轮廓变化强的位置，同时不允许局部额外产生 Token。随后直接从原图读取 RGB，因此模型不会从 CNN Stem 自

动获得局部纹理。坐标、层级、法线进度、法线长度和局部弧长支撑量告诉 Mamba 这些不规则像素序列的几何含义。叶子分数也按弧长加权，避免高密度区域仅因点数更多而占优。

代价与并行性。 选择性扫描的计算量与实际路由样本数线性相关，包括普通和终止法线、每次轮廓扫描的两个方向、树段 Token 以及最终叶子 Token。路线构建还包含显著性、Sobel、等高线树和最终碰撞查询；含 V 个路线网格顶点的标准等高线树通常为 $O(V \log V)$ [4]。大量短而不规则的序列、填充和树同步仍可能降低 GPU 利用率。

公平比较需要匹配 Token 宽度和训练方案，包含原图像素或 Token 数匹配的基线，并把确定性路线构建计入端到端延迟。路由 Token 数和渐近复杂度都不能单独代表真实运行速度。

7 讨论与局限

初版频率调谐场表示自底向上的对比度，不一定等于分类任务需要的语义重要性，因此“低到高”只表示显著性顺序。第 8 节简述了用可训练 CNN 替换路线场的方案，同时保留硬拓扑的明确梯度边界。

几何预处理有意保持简单：热力图平滑一次、Sobel 强度沿圈平滑一次、过滤小圈，不做持久性简化。细小树枝可以存在于完整拓扑中，却没有扫描 Token；这能节省计算，也可能遗漏有效细节。补边矩形保证等高线树有效，有孔洞的掩膜区域需要 Reeb 图，平坦区需要确定性的符号破平局规则。

直接读取 RGB 取消了 CNN 特征 Stem，也同时取消了 CNN 天然提供的局部纹理聚合。模型只能看到法线和轮廓实际经过的像素，稀疏路线可能漏掉路线之间的证据，法线长度上限也可能降低覆盖率。因此，小图块采样、浅层特征适配器和额外局部扫描都应作为基线或后续扩展，而不是初版中隐藏的组成部分。

带 Tag 的 y 是紧凑接口，不保证完整保存长分支信息；分裂复制它也不会产生不同的既往历史。终止圈虽然读取两侧，但碗形或非凸区域的射线仍可能重叠。统一 Sobel 规则还会让强变化区域同时得到更密采样并靠近闭环终点，因此消融实验需要把这两种作用分开。

最后，不规则短序列即使具有线性复杂度，也可能比规则栅格更难高效运行。任何实证比较都需要报告显著性计算、轮廓构建、碰撞查询、空路线比例、填充开销和真实延迟。本文贡献是完整的路线构建和结构分析，而不

是精度、鲁棒性、显存效率或吞吐率方面的实测提升；人类阅读过程只是信息调度的启发，不是生物视觉声明。

8 拓展

下面几项用于拓展当前初版架构：

- **可训练的结构图**：使用端到端或单独训练的卷积模块，生成与输入空间尺寸对应的结构强度图。
- **主方向环扫描**：以每个等高线采样点为中心建立多层同心环，取代法线扫描。用局部主方向统一每个环的起点、返回点和汇集位置；先沿各环进行双向 Mamba 扫描，再按照从外到内的顺序把各环状态汇聚到中心。
- **层间稠密扫描**：在相邻等高线之间加入横向和纵向扫描，补充稀疏法线未读取的区域，再把稠密状态汇聚到附近的等高线采样点。等高线上也进行逐像素的稠密采样。
- **稠密层采样**：连续保留相邻层级，使层与层之间不留间隔。该方案取消法线扫描，只扫描稠密分布的等高线采样点，由相邻采样层形成连续覆盖。

9 结论

TopoContour-Mamba 把确定性显著性场转化为随图像变化的视觉伪时序，同时直接从原始 RGB 图像读取内容。同一张 Sobel 场为整圈选择低显著性侧，在周长固定的点数预算内重分配采样点，并确定公共锚点。反向法线和双向闭环独立编码每个轮廓；终止圈通过第二次闭环汇集两侧法线。随后，稀疏增广等高线树从低到高汇总带 Tag 的轮廓输出，用复制处理分裂，用与排列无关的融合处理汇合。最终叶子只在全局读出时按实际读取区域的显著性排序。与自适应排列或空间分区不同，本文保留等值线分量的分裂与汇合演化，并把局部读取与全局拓扑分开。本文完整定义这一机制，但不声称实证性能优势。学习型显著性、更丰富的原图读取、分支摘要和树并行执行属于可选扩展。

参考文献

- [1] Radhakrishna Achanta, Sheila S. Hemami, Francisco Estrada, and Sabine Süsstrunk. Frequency-tuned salient region detection. In *IEEE Conference on Computer Vision and Pattern Recognition*, pages 1597–1604, 2009.
- [2] Diego Adame, Jose A. Nunez, Fabian Vazquez, Nayeli Gurrola, Huimin Li, Haoteng Tang, Bin Fu, and Pengfei Gu. Topo-vm-unetv2: Encoding topology into vision mamba unet for polyp segmentation. *arXiv preprint arXiv:2505.06210*, 2025.
- [3] Ali Behrouz and Farnoosh Hashemi. Graph mamba: Towards learning on graphs with state space models. *arXiv preprint arXiv:2402.08678*, 2024.
- [4] Hamish Carr, Jack Snoeyink, and Ulrike Axen. Computing contour trees in all dimensions. *Computational Geometry*, 24(2):75–94, 2003.
- [5] Albert Gu and Tri Dao. Mamba: Linear-time sequence modeling with selective state spaces. In *Conference on Language Modeling*, 2024.
- [6] Charles Gueunet, Pierre Fortin, Julien Jomier, and Julien Tierny. Task-based augmented contour trees with fibonacci heaps. *IEEE Transactions on Parallel and Distributed Systems*, 30(8):1889–1905, 2019.
- [7] Linfeng He, Meiqin Liu, Qi Tang, Chao Yao, and Yao Zhao. Mambavsr: Content-aware scanning state space model for video super-resolution. *arXiv preprint arXiv:2506.11768*, 2025.
- [8] Wenchong He, Arpan Man Sainju, Zhe Jiang, and Da Yan. Deep neural network for 3d surface segmentation based on contour tree hierarchy. *arXiv preprint arXiv:2008.11269*, 2020.
- [9] Yi-Kuan Hsieh, Jun-Wei Hsieh, Xin Li, Ming-Ching Chang, and Yu-Chee Tseng. Partial ring scan: Revisiting scan order in vision state space models. *arXiv preprint arXiv:2602.04170*, 2026.
- [10] Tao Huang, Xiaohuan Pei, Shan You, Fei Wang, Chen Qian, and Chang Xu. Localmamba: Visual state space model with windowed selective scan. In *European Conference on Computer Vision Workshops*, 2024.
- [11] Laurent Itti, Christof Koch, and Ernst Niebur. A model of saliency-based visual attention for rapid scene analysis. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 20(11):1254–1259, 1998.
- [12] Tanzhe Li, Caoshuo Li, Jiayi Lyu, Hongjuan Pei, Baochang Zhang, Taisong Jin, and Rongrong Ji. Damamba: Vision state space model with dynamic adaptive scan. In *Advances in Neural Information Processing Systems*, 2025.
- [13] Yue Liu, Yunjie Tian, Yuzhong Zhao, Hongtian Yu, Lingxi Xie, Yaowei Wang, Qixiang Ye, Jianbin Jiao, and Yunfan Liu. Vmamba: Visual state space model. In *Advances in Neural Information Processing Systems*, 2024.
- [14] Mohit Sharma and Vijay Natarajan. On-demand augmentation of contour trees. In *11th Indian Conference on Computer Vision, Graphics and Image Processing*, pages 104:1–104:8, 2018.

- [15] Fei Xie, Weijia Zhang, Zhongdao Wang, and Chao Ma. Quadmamba: Learning quadtree-based selective scan for visual state space model. In *Advances in Neural Information Processing Systems*, 2024.
- [16] Chenhongyi Yang, Zehui Chen, Miguel Espinosa, Linus Ericsson, Zhenyu Wang, Jiaming Liu, and Elliot J. Crowley. Plainmamba: Improving non-hierarchical mamba in visual recognition. In *British Machine Vision Conference*, 2024.
- [17] Lianghui Zhu, Bencheng Liao, Qian Zhang, Xinlong Wang, Wenyu Liu, and Xinggang Wang. Vision mamba: Efficient visual representation learning with bidirectional state space model. In *Proceedings of the 41st International Conference on Machine Learning*, 2024.

A 参考配置

表 2 给出一组可复现的起始配置，并非调优后的最优值。

表 2: 224×224 原图和 56×56 路线网格的默认参数。

项目	默认值
显著性	频率调谐 Lab; 1–99 百分位截断
平滑	高斯, 原图尺度 $\sigma = 3$ 像素
Sobel	平滑 S 上的 3×3 核; 试探点双线性读取
边界/剖分	一圈低值边框/固定西北–东南对角线
保留层级	12 个内部均匀层级
小圈过滤	周长 ≥ 12 , 面积 ≥ 8 ; 无持久性过滤
点数预算	$N_C = \max(16, \text{round}(P_C/2))$; 无上限
试探点	$2N_C$ 个弧长均匀点
普通读取侧	平均带符号法线 Sobel 响应所指示的低值侧
强度平滑	一次闭环 (1, 2, 3, 2, 1)/9 卷积
密度权重	$\text{clip}(\bar{g}/(\text{median}^+ \bar{g} + \epsilon), 1, 3)$
锚点 p_0	最大平滑未截断 $\bar{g}$; 按 (y, x) 破平局
碰撞集合	保留轮廓折线与补边框; 仅最终点查询
法线样本	沿射线均匀读取原图, 样本数限制为 2–32
叶子分数	两侧实际法线读取的弧长加权显著性均值

每个圈统一定向为顺时针。均匀试探点读取 $r_i = G(u_i)^\top n_i$: 平均符号选择低值普通侧, 闭环平滑后的绝对强度决定密度, 最大未截断强度确定 p_0 。平均符号为零时选择负法线侧; 整圈强度为零时使用均匀密度和坐标破平局。累计加权弧长返回恰好 N_C 个唯一位置并保留 p_0 。只有最终点执行碰撞查询, 且忽略起点接触和本圈相邻线段。动态二次幂长度桶可以超过 256; 极长序列可在不丢点的前提下精确分块。

表 3: 初始模型默认参数。

项目	默认值
Token 宽度/SSM 状态宽度	192 / 16
输入嵌入	共享逐点线性层或 MLP; 无 CNN Stem
法线输入	RGB、层级/差值、 (x, y) 、进度、法线长度
轮廓输入	法线摘要、RGB、 (x, y) 、层级、弧长支撑、法线几何
Normal/Contour/Tree 层数	1 / 2 / 1
扩张率/局部卷积宽度	2 / 4
方向参数	共享; 拼接、投影、LayerNorm
跨树段状态	仅带 Tag 的 y ; 不传 h 或缓存
汇合先验	$\frac{1}{2} \log(1 + Q_i)$; 学习门末层零初始化
Tag 种类	法线、轮廓、树段、汇合、叶子、最终、空路线
长度桶	动态二次幂; 可选精确分块
空路线	原图 RGB 通道均值和方差的投影
随机深度	0.1

每条真实序列终点都带 Tag。法线序列从碰撞点开始, 在轮廓点结束; 闭环序列从不带 Tag 的 p_0 开始, 完整绕圈后在带 Tag 的第二个 p_0 结束。树源使用可学习 Token, 树段在最后一个真实轮廓结束。终止圈的最终 Token 同时包含普通侧、相反侧、第一次闭环和第二次闭环信息。所有最终叶子都带叶子 Tag, 最后一个再带最终 Tag; 单叶同样执行最终扫描。

评估建议。 首轮 ImageNet-1K 实验可使用 AdamW 训练 300 轮, 批量 1024, 学习率 10^{-3} , 20 轮预热和余弦衰减, 权重衰减 0.05, 标签平滑 0.1, 梯度裁剪 1.0, 并报告三个随机种子。空间增强后重新计算显著性与路线。固定路线基线应匹配输入投影、Token 宽度、Mamba 层数、训练方案以及全网格或路由 Token 数。消融路线/叶子顺序、采样、终止双侧读取、局部输入、树汇合、Tag 和硬/软路线; 同时报告精度、Token 数、延迟、填充率、射线重叠与空路线比例。